

Лабораторная работа №4

“Экстраполяция данных”

Цель работы: изучение методов экстраполяции данных, получение начальных навыков работы с библиотекой pandas и методы аппроксимации в библиотеке numpy.

Ход работы:

№	Описание проделанных действий	Результат этапа
1	Ознакомление с теоретическими сведениями о методах аппроксимации и экстраполяции данных. Анализ метода наименьших квадратов как критерия близости аппроксимирующей функции к экспериментальным данным. Изучение требований лабораторной работы.	Сформирован четкий алгоритм реализации; выбраны программные инструменты (Python, библиотеки Pandas, NumPy, Matplotlib) для загрузки, обработки данных, построения полиномиальных моделей и визуализации результатов.
2	Загрузка данных из файла с использованием библиотеки Pandas. Изучение структуры таблицы: вывод информации о типах данных и просмотр содержимого. Выявление пропусков и некорректных значений в столбце цены открытия <OPEN>.	Получен датафрейм с исходными котировками. Обнаружены строки с некорректными (нечисловыми) значениями, требующие очистки перед построением аппроксимирующих моделей.
3	Подготовка данных для аппроксимации: преобразование столбца <OPEN> в числовой тип с заменой некорректных значений на NaN, удаление строк с пропусками, приведение к типу float64. Повторный вывод информации о датафрейме для контроля качества очистки.	Данные полностью подготовлены для дальнейшей работы: удалены все некорректные и пропущенные значения, столбец <OPEN> имеет числовой тип float64. Количество строк датафрейма сокращено до числа корректных записей.

4	Построение полиномиальных моделей аппроксимации по первым 15 дням (строкам таблицы). Создание трех моделей: полином 1-й степени (линейный), полином 2-й степени (квадратичный), полином 7-й степени (высокого порядка).	Получены три аппроксимирующие модели разной степени сложности. Каждая модель описывает зависимость цены открытия от номера дня на обучающем интервале (дни 1-15).
5	Расчет суммы квадратов ошибок (SSE) для каждой модели на обучающих данных. Построение первого графика: исходные данные (первые 15 дней) и три аппроксимирующие кривые (1, 2, 7 степени). Нанесение на график значений SSE для визуальной оценки точности моделей внутри интервала аппроксимации.	Получен наглядный график, демонстрирующий поведение полиномов на интервале обучения. Установлено, что с ростом степени полинома SSE уменьшается: полином 7-й степени проходит практически через все точки, обеспечивая минимальную погрешность.
6	Использование построенных моделей для прогнозирования (экстраполяции) цены открытия на оставшиеся дни (16-25). Расчет SSE для прогнозных значений каждой модели. Построение второго графика на одном рисунке: исходные данные по всем дням, аппроксимирующие кривые на обучающем интервале, прогнозные значения. Указание на графике SSE прогноза для каждой модели.	Получен комплексный график, совмещающий исходные данные, аппроксимацию и прогноз. Визуально видно, что полином 7-й степени, идеально описывающий обучающие данные, дает резкие и нереалистичные колебания за пределами интервала аппроксимации.
7	Анализ полученных результатов и формулирование выводов. Сравнение точности моделей внутри интервала аппроксимации (на обучающих данных) и за его пределами (на прогнозных данных). Оценка явления переобучения для полинома высокой степени.	Сделаны выводы: внутри интервала аппроксимации точность растет с увеличением степени полинома. Доказано, что для задач прогнозирования временных рядов предпочтительнее использовать простые модели, устойчивые к экстраполяции.

Выводы:

- Точность аппроксимации (внутри интервала): С увеличением степени полинома точность описания исходных данных растёт, а сумма квадратов ошибок (SSE) снижается. Полином 7-й степени обеспечивает минимальное отклонение от точек, так как его гибкости достаточно для прохождения практически через каждый узел обучающей выборки.
- Точность прогнозирования (вне интервала): Высокая степень полинома приводит к переобучению: модель начинает описывать случайный шум, а не общую закономерность. Это вызывает резкие и нереалистичные колебания за пределами известных данных. В то же время модели низких степеней (1 и 2) лучше сохраняют общий тренд и дают более стабильный, хоть и упрощенный прогноз.

Использованные в работе функции:

Функция	Назначение	Основные параметры
pd.read_csv()	Чтение данных из CSV-файла в объект DataFrame	filepath_or_buffer - путь к файлу; sep - символ-разделитель (например, ';')
df.info()	Вывод информации о датафрейме: типы данных, количество ненулевых значений	–
df.to_numpy()	Преобразование столбца/датафрейма в массив NumPy	–
df.dropna()	Удаление строк, содержащих пропущенные значения (NaN)	subset - список столбцов для проверки; inplace - заменять ли исходный DataFrame
df.reset_index()	Сброс индексов DataFrame, создание нового числового индекса	drop - удалять ли старый индекс; inplace - заменять ли исходный DataFrame
pd.to_numeric()	Преобразование значений в числовой тип, некорректные в NaN	arg - данные для преобразования; errors - реакция на ошибки ('coerce', 'raise', 'ignore')

df.astype()	Приведение столбца/датафрейма к указанному типу данных	dtype - целевой тип данных (например, 'float64')
Polynomial.fit()	Построение аппроксимирующего полинома методом наименьших квадратов	x, y - данные; deg - степень полинома
Polynomial()	Создание объекта полинома с заданными коэффициентами	coeff - массив коэффициентов (от младшей степени к старшей)
np.arange()	Генерация массива чисел с заданным шагом	start, stop, step - начало, конец, шаг
np.sum()	Вычисление суммы элементов массива	a - массив; axis - ось суммирования (опционально)
np.min() / np.max()	Нахождение минимального/максимального значения в массиве	a - массив; axis - ось (опционально)
plt.figure()	Создание нового окна (фигуры) для отрисовки графиков	figsize - размер окна в дюймах (ширина, высота)
plt.plot()	Построение линейного графика или маркеров по точкам	x, y - данные; color - цвет; marker - маркер; linestyle (ls) - стиль линии; label - подпись
plt.xlabel() / plt.ylabel()	Подпись осей координат X и Y соответственно	xlabel / ylabel - текст подписи
plt.title()	Установка заголовка для графика	label - текст заголовка
plt.ylim()	Установка границ отображения по оси Y	bottom, top - нижняя и верхняя граница
plt.legend()	Отображение легенды на графике	loc - расположение; fontsize - размер шрифта
plt.grid()	Добавление сетки на координатную плоскость	True/False; axis - 'both', 'x' или 'y'
plt.show()	Отображение всех построенных графиков на экране	—